

Trabalho Final – Quarta Questão: Destilação de Conhecimento Step-by-Step (CoT) de Qwen2.5-7B para Qwen2.5-0.5B

Émery Freitas Moriconi¹, Felipe Lages de Lima¹,
Eryck Kawã Pereira Torres¹, Raffael Ferreira Fernandes¹

¹Bacharelado em Ciência da Computação
Universidade Federal do Piauí (UFPI)
Tópicos em Inteligência Artificial

Abstract. This report presents the fourth question of the final Artificial Intelligence assignment: knowledge distillation from a teacher language model to a smaller student. A Qwen2.5-7B-Instruct teacher was distilled into a Qwen2.5-0.5B-Instruct student (a $\sim 14\times$ parameter reduction) using Step-by-Step (Chain-of-Thought) distillation, training LoRA adapters on the synthetic corpus generated by the teacher from the *docentesDC* dataset. The model was evaluated before and after distillation over a 100-question benchmark, with no data leakage. Knowledge transfer was confirmed: test perplexity decreased 30.7% (from 6.52 to 4.52) and ROUGE-L increased from 0.175 to 0.226. Qualitative analysis showed a second conclusion: CoT distillation successfully transfers the teacher’s reasoning behavior and style, but factual knowledge transfer is partial, limited by the 0.5B student’s capacity.

Resumo. Este relatório apresenta a quarta questão do trabalho final de Inteligência Artificial: destilação de conhecimento de um modelo professor para um aluno menor. Um professor Qwen2.5-7B-Instruct foi destilado em um aluno Qwen2.5-0.5B-Instruct (redução de $\sim 14\times$ em parâmetros) usando destilação Step-by-Step (Chain-of-Thought), treinando adaptadores LoRA sobre o corpus sintético gerado pelo professor a partir do dataset *docentesDC*. O modelo foi avaliado antes e depois da destilação sobre um benchmark de 100 perguntas, sem vazamento de dados. A transferência de conhecimento foi confirmada: a perplexidade de teste caiu 30,7% (de 6,52 para 4,52) e o ROUGE-L subiu de 0,175 para 0,226. A análise qualitativa mostrou uma segunda conclusão: a destilação CoT transfere com sucesso o comportamento de raciocínio e o estilo do professor, mas a transferência de conhecimento factual é parcial, limitada pela capacidade do aluno de 0,5B.

1. Introdução

O objetivo da quarta questão do trabalho final foi executar e avaliar um processo de destilação de conhecimento entre modelos de linguagem. O foco do relatório é demonstrar três pontos: quais decisões técnicas foram tomadas, quais resultados foram obtidos e o que esses resultados indicam sobre a viabilidade de transferir capacidade de um modelo grande para um modelo pequeno em domínio restrito.

A destilação de conhecimento é uma técnica de compressão na qual um modelo menor (aluno) é treinado para reproduzir o comportamento de um modelo maior (professor), reduzindo tamanho, latência e custo de inferência. Diferentemente do fine-tuning supervisionado das Questões 2 e 3 — em que o modelo aprende a partir de respostas de referência fixas — na destilação o sinal de treino é produzido pelo próprio professor. A hipótese inicial foi objetiva: a destilação Step-by-Step deveria transferir o comportamento de raciocínio do professor, melhorando o aluno em relação a seu estado base, ainda que a transferência de conhecimento factual pudesse ser limitada pelo porte reduzido do aluno.

2. Decisões Metodológicas

2.1. Modelos e Técnica

Definiu-se como professor o Qwen2.5-7B-Instruct e como aluno o Qwen2.5-0.5B-Instruct. A escolha pela mesma família foi pragmática e traz uma vantagem técnica decisiva: ambos compartilham o mesmo *tokenizer*, eliminando a necessidade de estender o vocabulário — problema enfrentado nas Questões 2 e 3 com o GPT-2. O aluno de aproximadamente 500 milhões de parâmetros cabe no ambiente disponível e representa uma redução de cerca de 14 vezes em relação ao professor.

Embora a mesma família tornasse tecnicamente possível a destilação por *logits*, optou-se pela destilação Step-by-Step (Chain-of-Thought) por dois motivos. Primeiro, restrições de memória: manter o professor de 7B e o aluno de 0,5B simultaneamente com *logits* em ambiente Colab com GPU T4 é custoso. Segundo, o ganho qualitativo de transferir o *raciocínio*, e não apenas a decisão final. Conforme o material da disciplina, a destilação CoT faz o aluno “imitar o pensamento”, favorecendo generalização e interpretabilidade frente à destilação tradicional.

2.2. Geração do Dataset Sintético

O dataset foi gerado a partir do corpus *docentesDC*, o mesmo utilizado nas Questões 2 e 3, garantindo comparabilidade. O professor Qwen2.5-7B, executado localmente via Ollama com quantização Q4_K_M, produziu para cada fragmento de documento um par no formato {instruction, input, reasoning, answer}, com raciocínio explícito passo a passo. A geração foi incremental com *checkpoint*, permitindo retomada em caso de interrupção, e alcançou 92% de aproveitamento após um pré-filtro que descarta fragmentos ruidosos, como código-fonte, texto em inglês e listas de nomes.

A validação aplicou filtros de qualidade: descarte de raciocínio ou resposta curtos, detecção heurística de idioma, verificação de consistência entre raciocínio e resposta, e deduplicação por *hash* da instrução. Um achado importante foi que o professor frequentemente inseria referências ao contexto de origem (“o trecho menciona...”) no raciocínio. Em vez de descartar esses pares, um script de limpeza reescreveu os raciocínios removendo essas construções, recuperando 330 pares que seriam perdidos. O conjunto final foi de 1.077 pares CoT válidos, de 1.400 gerados.

3. Configuração do Experimento

O experimento separou os pares em treino, validação e teste, na proporção 85/10/5. O benchmark de 100 perguntas foi removido do conjunto de treino, com prevenção rigorosa de vazamento de dados: além da exclusão exata, removeram-se 18 perguntas com quase-duplicata (similaridade de Jaccard superior a 0,7) presentes no treino, resultando em interseção conceitual nula entre avaliação e treino.

O treino utilizou o *chat template* nativo do Qwen2.5, com alvo de aprendizado composto pelo raciocínio seguido da resposta final. Os tokens do *prompt* receberam valor -100 no vetor de rótulos, sendo excluídos da função de perda; apenas os tokens da resposta contribuem para o gradiente. A Tabela 1 apresenta a configuração principal.

Table 1. Configuração principal do treinamento de destilação

Parâmetro	Valor
Modelo base (aluno)	Qwen2.5-0.5B-Instruct
Estratégia	LoRA (SFT)
Camadas-alvo	q,k,v,o_proj, gate/up/down_proj
Rank / Alpha / Dropout	16 / 32 / 0,05
Percentual treinável	$\sim 1,7\%$
block_size	512 (0% de truncamento; p95 = 225)
grad_accum_steps	8 (batch efetivo 16)
learning_rate	0,0002 (scheduler cosine)
Épocas	3
Ambiente	Google Colab, GPU Tesla T4

A curva de treino evidenciou *overfitting*: a perda de treino caiu de 1,72 para aproximadamente 1,11, enquanto a perda de validação atingiu o mínimo no passo 50 (*eval_loss* 1,55; perplexidade de validação $\sim 4,72$) e subiu levemente em seguida. O mecanismo `load_best_model_at_end` garantiu que o adaptador final corresponde ao melhor *checkpoint* de validação, mitigando o efeito. Esse comportamento é esperado dado o dataset restrito de 1.077 pares e a rápida memorização do modelo.

4. Resultados

A avaliação comparou três variantes sobre o mesmo benchmark de 100 perguntas e o mesmo conjunto de teste: o professor de 7B (teto de referência, avaliado com quantização NF4 em 4 bits para caber na GPU T4), o aluno de 0,5B sem destilação (base) e o aluno de 0,5B destilado. As métricas foram perplexidade sobre o conjunto de teste, ROUGE-L, cobertura de termos-chave e taxa de respostas em português. Todas as variantes usaram geração determinística (*greedy*). A Tabela 2 apresenta os resultados.

O resultado central é positivo: houve transferência de conhecimento. O aluno destilado superou o aluno base em perplexidade, com redução de 30,7% (de 6,52 para 4,52), e em ROUGE-L, com ganho de 0,051 (de 0,175 para 0,226). Ambas as variantes mantiveram 100% de respostas em português — diferentemente do GPT-2 da Questão 2, o Qwen2.5 não apresentou o problema de mistura de idioma nem em seu estado base. Como o

Table 2. Comparativo das três variantes sobre o benchmark de 100 perguntas

Variante	PPL	ROUGE-L	Cobertura	% PT
Teacher 7B (referência, 4-bit)	5,85	0,212	0,675	100%
Student 0.5B (base, antes)	6,52	0,175	0,559	100%
Student 0.5B (destilado, depois)	4,52	0,226	0,409	100%

conjunto de teste não foi usado no treinamento, a melhora indica generalização dentro do domínio.

5. Discussão dos Resultados

5.1. O aluno destilado apresenta perplexidade menor que o professor

Um resultado aparentemente paradoxal é que o aluno destilado (PPL 4,52) obteve perplexidade menor que o professor (5,85). Isso não indica que o aluno “sabe mais” que o professor. A perplexidade é medida sobre um conjunto de teste composto por respostas geradas pelo próprio professor — exatamente o estilo que o aluno foi treinado para imitar. O aluno está, portanto, bem ajustado à distribuição de teste, enquanto o professor, avaliado quantizado em 4 bits e não afinado para esse formato específico, apresenta perplexidade ligeiramente maior. É um artefato da metodologia de destilação, não uma superação real de capacidade.

5.2. Forma versus conhecimento factual

A métrica de cobertura revela a capacidade real: professor (0,675) > base (0,559) > destilado (0,409). O professor menciona mais termos-chave corretos, como esperado. A inspeção qualitativa confirma esse padrão. Em perguntas como “o que é MOM (Message Oriented Middleware)”, o aluno base respondeu corretamente, enquanto o destilado produziu resposta mais concisa porém factualmente incorreta. A Tabela 3 ilustra o comportamento.

Table 3. Exemplos qualitativos de respostas do aluno base e destilado

Pergunta	Aluno base	Aluno destilado
O que é MOM (Message Oriented Middleware)?	Message-Oriented Middleware; sistemas de comunicação em ambientes empresariais (correto).	Bibliotecas para desenvolvimento web em Java (incorreto).
Diferença entre instruções privilegiadas e não privilegiadas?	Determinam se a operação pode ser realizada conforme o nível de privilégio (correto).	Executadas com maior segurança em sistemas de alto nível (vago).

Isto evidencia a natureza da destilação para modelos muito pequenos: a técnica transferiu com sucesso o comportamento de raciocínio e o estilo do professor, refletido na queda de perplexidade e no ganho de ROUGE-L, mas a transferência de conhecimento factual foi

parcial, limitada pela capacidade de 0,5B do aluno. A queda da cobertura, acompanhada do aumento de ROUGE-L, indica que o aluno destilado aprendeu a ser mais conciso e estruturalmente similar às respostas de referência, em vez de mencionar muitos termos de forma dispersa. Esse resultado é coerente com a literatura sobre destilação para *Small Language Models*.

6. Conclusão

O trabalho implementou um pipeline completo para a quarta questão do trabalho final: geração sintética de dataset CoT via professor Qwen2.5-7B, filtragem e limpeza resultando em 1.077 pares, construção de um benchmark de 100 perguntas com prevenção de vazamento, destilação com LoRA e avaliação antes e depois do processo.

O objetivo principal foi alcançado. A perplexidade de teste do aluno caiu 30,7% (de 6,52 para 4,52) e o ROUGE-L subiu de 0,175 para 0,226, confirmando a transferência de conhecimento do professor para o aluno. A contribuição do ponto de vista de Ciência da Computação é a engenharia de compressão de modelos: viabilizar inferência local e barata com um modelo 14 vezes menor, quantificando o compromisso entre qualidade e custo.

A avaliação qualitativa mostrou o limite dessa abordagem. A destilação transferiu o comportamento de raciocínio, mas não todo o conhecimento factual do professor, em razão do porte reduzido do aluno. As principais limitações são o tamanho do modelo de 0,5B, o dataset restrito e o *overfitting* observado no treino. Como continuidade, o trabalho poderia ampliar o dataset, utilizar alunos intermediários de 1,5B a 3B parâmetros, e aplicar filtragem de qualidade por confiança do professor para reduzir a propagação de erros factuais.

References

- [1] VOGADO, L. H. S. *Destilação de LLMs*. Material da disciplina Tópicos em Inteligência Artificial, DC/UFPI, maio de 2026.
- [2] HSIEH, C.-Y. et al. Distilling Step-by-Step! Outperforming Larger Language Models with Less Training Data and Smaller Model Sizes. *Findings of ACL*, 2023.
- [3] HINTON, G.; VINYALS, O.; DEAN, J. Distilling the Knowledge in a Neural Network. arXiv:1503.02531, 2015.
- [4] DEEPSEEK-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. arXiv:2501.12948, 2025.
- [5] HU, E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations*, 2022. Disponível em: <https://arxiv.org/abs/2106.09685>.
- [6] QWEN TEAM. Qwen2.5 Technical Report. arXiv:2412.15115, 2024. Disponível em: <https://arxiv.org/abs/2412.15115>.

- [7] HuggingFace PEFT Library. Disponível em: <https://github.com/huggingface/peft>. Acesso em: jul. 2026.